



Instituto Politécnico Nacional
Unidad Profesional Interdisciplinaria de Ingeniería
Campus Tlaxcala



Reporte Técnico/Tesis

"Reconstrucción 3D de escenas interiores mediante cámaras RGB-D"

No. TT: TT2026-1_IA14

Presenta(n):

René Alejandro Santos Mora
Victor Hugo Tecpa Cisneros

Asesores:

Dr. Esau Eliezer Escobar Juárez

Dr. Ricardo Ramos Aguilar

Tlaxcala, Tlaxcala, a **29** de **10** de **2025**

"La Técnica al Servicio de la Patria"

RESUMEN

El proyecto propuesto tiene como objetivo la reconstrucción 3D de entornos interiores tales como recamaras, baños, salas de estar siempre y cuando estos esten delimitados dentro de 4 paredes, un techo y un suelo mediante el uso de una cámara RGB-D. Esto se logrará mediante una metodología robusta y adaptable a equipos de cómputo de baja gama, que integra técnicas de visión artificial, filtrado de datos y aprendizaje profundo, como las redes neuronales, además de fusión de múltiples vistas. El propósito es generar representaciones digitales que se puedan considerar un gemelo digital visualmente representativo pueda usarse para aplicaciones en diseño de interiores, realidad aumentada y robótica.

La metodología propuesta abarca desde la adquisición de datos hasta la evaluación del sistema mediante benchmarks especializados. Se espera que este sistema sirva como base para desarrollos más complejos, ofreciendo una solución de bajo costo y bajo consumo de recursos, utilizando equipos accesibles.

A diferencia de los sistemas basados en sensores LiDAR, que permiten obtener reconstrucciones 3D pero cuyo costo puede oscilar entre \$6,000 y \$12,000 MXN, la propuesta se enfoca en el uso exclusivo de cámaras RGB-D, las cuales se encuentran en un rango de precios más asequible, de aproximadamente \$2,000 a \$3,000 MXN.

Términos/Palabras Clave

- Visión artificial
- aprendizaje profundo
- Reconstrucción 3D
- Cámara RGBD

ÍNDICE GENERAL

1	Introducción	1
1.1	Antecedentes	2
1.2	Planteamiento del Problema	2
1.3	Objetivos	2
1.3.1	Objetivo General	2
1.3.2	Objetivos Específicos	3
1.4	Justificación	3
1.5	Hipótesis	3
1.6	Aportación Científica y/o Tecnológica	4
2	Marco Teórico	5
2.1	Base de datos utilizada: SUN RGB-D	5
2.2	Preprocesamiento de Imágenes	5
2.2.1	RGB-D:	6
2.2.2	Imágenes de Profundidad:	6
2.3	Modelo para Relleno de Profundidad	6
2.3.1	Arquitectura Encoder-Decoder:	6
2.4	Reconstrucción 3D con Total Scene Understanding	7
3	Estado del arte	8
3.1	Análisis de trabajos relacionados	9
3.2	Conclusión del análisis de la literatura	15
4	Metodología	17
4.1	Entorno de Desarrollo	17
4.2	Arquitectura del Sistema Propuesto	18
4.3	Obtención de imágenes RGB	18
4.4	Filtrado del ruido	20
4.5	Relleno de profundidad	21
4.6	Validación del Modelo de Profundidad	22
4.7	Calibración de la cámara	22
4.8	Procesamiento Semántico y Segmentación de Instancias	23
4.9	Reconstrucción de superficies y Fusión Semántica	23
4.10	Evaluación de resultados	24
4.10.1	Métricas de Trayectoria y Odometría (SLAM)	24

4.10.2	Métricas de Evaluación Semántica	24
4.10.3	Métricas de Evaluación de la reconstrucción	24
4.11	Cronograma	25
4.11.1	Actividades asignadas en cada parte:	25
5	Resultados	27
5.0.1	Modelo de Profundidad	27
5.0.2	Segmentación de objetos	30

CAPÍTULO 1

INTRODUCCIÓN

La capacidad de manipular entornos digitales antes de que tomen una forma material ha revolucionado industrias como el diseño y la manufactura. Un ejemplo claro es la impresión 3D, que permite iterar y perfeccionar un objeto digitalmente antes de comprometer recursos físicos. La creación de un modelo digital previo al físico resulta, por tanto, altamente beneficiosa.

Un ejemplo de ello se encuentra en la industria de la construcción con el concepto de "orden de cambio": un costo adicional que surge ante modificaciones imprevistas. Estos pueden representar hasta un 10% del costo original de la obra, generando desperdicio de materiales y mano de obra. La modelación y el diseño en un entorno digital permiten anticipar estos problemas, evitando sobrecostos y optimizando los recursos.

Este mismo principio se aplica a la arquitectura y al diseño de interiores, donde la reconstrucción 3D de un espacio físico en un modelo digital es el primer paso crucial. Específicamente, la capacidad de escanear y modelar espacios interiores comunes, como habitaciones, oficinas o salas de estar, permite una planificación y modificación sin límites, eliminando la necesidad de realizar costosos cambios físicos [16].

Para que estas representaciones digitales sean útiles en aplicaciones prácticas (como el diseño de interiores, la realidad aumentada o la robótica), se requiere que la reconstrucción sea dimensionalmente coherente y de alta fidelidad visual. Es decir, el modelo debe capturar fielmente la escala y las proporciones del entorno real, permitiendo una planificación espacial fiable.

Aquí es donde surge el objetivo de este proyecto el cual es lograr este nivel de fidelidad ha dependido tradicionalmente de equipos de escaneo profesional como el LiDAR, cuyo alto costo limita su accesibilidad. Esto ha motivado la búsqueda de métodos alternativos que logren reconstrucciones de alta calidad utilizando sensores de bajo costo, como las cámaras RGB-D.

1.1 Antecedentes

1.2 Planteamiento del Problema

La reconstrucción 3D de alta calidad es un tema importante en gráficos por computadora y visión artificial, principalmente porque permite crear gemelos digitales de entornos reales [8] sirviendo como base para aplicaciones como la realidad virtual, videojuegos o simuladores de entrenamiento. [12] [34] Esto tiene diversas utilidades en diferentes campos, facilitando cómo se pueden manipular ciertos entornos, como la modificación de una arquitectura. Es más práctico manipular un medio digital que uno físico, ya que los cambios de diseño, materiales o distribución se pueden ejecutar de forma instantánea y reversible en un software, eliminando los costos de material y mano de obra que implicaría un prototipo físico.

Sin embargo, el proceso presenta desafíos técnicos. Las reconstrucciones 3D realizadas con cámaras RGB-D son ruidosas e incompletas; esto ocurre porque el sensor de profundidad infrarrojo de la cámara falla al interactuar con ciertas superficies. [1] Por ejemplo, los materiales brillantes o transparentes dispersan o dejan pasar la luz de forma errática, mientras que los objetos que están lejos devuelven una señal demasiado débil para una medición precisa. Debido a estos fallos del sensor, obtener modelos de escenas 3D de alta calidad sigue siendo un desafío para los sistemas existentes[7].

Esto crea un problema reestructivo para la creación de estas reconstrucciones que se da ya que existe gran accesibilidad de las cámaras RGB-D comunes tales como la serie Intel RealSense o Azure Kinect y además una alta fidelidad de los escáneres LiDAR profesionales como los de Faro o Leica. Sin embargo hay un desequilibrio ya que mientras que las primeras son asequibles sufren de los fallos de sensor ya mencionados, los segundos ofrecen una precisión milimétrica, pero a un costo que los hace prohibitivos para muchas aplicaciones.

Además de las fallas en superficies reflectantes, los límites prácticos de las cámaras RGB-D incluyen un rango de profundidad efectivo limitado y una alta sensibilidad a las condiciones de iluminación ambiental, ya que la luz solar directa puede saturar el sensor infrarrojo lo que puede llegar a generar vacíos dentro de la detección de objetos.

La calidad de las reconstrucciones se va medir utilizando métricas estándar en la literatura. La calidad geométrica se evaluará midiendo la Precisión (Accuracy), que cuantifica la distancia media del modelo reconstruido al modelo real (Ground Truth), y la Completitud (Completeness), que mide qué porcentaje de la escena real fue capturada. además de utilizar ATE (Absolute Trajectory Error) que mide el error global y RPE (Relative Pose Error) mide la error local.

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar un sistema de reconstrucción 3D acotada a entornos interiores de alta calidad, utilizando hardware de bajo costo y técnicas avanzadas de visión artificial."

1.3.2 Objetivos Específicos

- Mejorar la calidad de las imágenes buscando una reducción medible del ruido y de las áreas faltantes.
- Estimar con precisión la posición de la cámara utilizando métodos híbridos y coincidencia de escenas densas DSM (Dense Scene Matching).
- Reconstruir superficies 3D de alta calidad fusionando imágenes RGB-D y aplicando segmentación precisa con FusionVision.
- Evaluar el desempeño del sistema utilizando métricas estándar para la evaluación de SLAM y odometría, el ATE cuantifica el error global del sistema, mientras que el RPE cuantifica el error local además de usar la métrica del (RMSE) la que compara todo con el 'ground truth' en un dataset sintético.

1.4 Justificación

La reconstrucción 3D tiene diversos usos en diferentes ámbitos, como el diseño de interiores, al crear entornos digitales más fáciles de manipular en comparación con entornos físicos. Esto también es de gran utilidad en el medio del entretenimiento, ya que permite simular interacciones de entornos mucho más diversos. [8]

Sin embargo, la adopción masiva de esta tecnología se ve frenada por un desafío ya que se puede observar que los equipos que cuentan con la alta fidelidad de los escáneres LiDAR profesionales y la accesibilidad de los sensores de bajo costo, como las cámaras RGB-D, aunque estos últimos producen reconstrucciones con ruido, oclusión y deriva significativa [19]. Por lo que existe un desequilibrio entre lo que se genera resultado de calidad y la accesibilidad de estos siendo más fácil conseguir el equipo de baja gama pero arriesgándose a una reconstrucción de una calidad menor.

Este proyecto busca abordar dicho desafío. Se van a utilizar modelos como un Encoder-Decoder (como EfficientNet”) para estimar la profundidad densa.

En el contexto de México, poder obtener reconstrucciones 3D con un bajo costo tendría un impacto directo en PYMEs (Pequeñas y Medianas Empresas) de los sectores de construcción y diseño, permitiéndoles adoptar tecnologías reconstrucción sin la inversión prohibitiva en hardware. A nivel institucional, este trabajo proveerá una herramienta accesible y robusta para los laboratorios de visión y robótica, potenciando futuras líneas de investigación.

1.5 Hipótesis

Se propone un modelo de aprendizaje profundo, basado en una arquitectura Encoder-Decoder, para el relleno y densificación de los mapas de profundidad, combinado con un método de odometría con filtrado semántico (que excluye objetos dinámicos) y coincidencia densa (DSM), lo cual permitirá para la estimación de la pose de la cámara,

lo cual permitirá compensar el ruido y los datos faltantes inherentes a los sensores de las cámaras RGB-D de bajo costo.

Este modelo será evaluado en benchmarks estándar (TUM RGB-D e ICL-NUIM), donde demostrará una reducción significativa del error ATE y RPE además de una medida del (RMSE) eficiente para considerarse una copia digital competente.

1.6 Aportación Científica y/o Tecnológica

Se tienen en cuenta diversos aportes al término de ese proyecto, estos son los siguientes:

- Se creará un desarrollo de un sistema de software modular que integra una arquitectura de aprendizaje profundo (Encoder-Decoder) para la densificación de profundidad con métodos de estimación de pose como DSM y fusión de superficies con FusionVision.
- La publicación del código fuente del sistema en un repositorio de acceso abierto, permitiendo a otros investigadores replicar los resultados, utilizar el sistema y construir sobre él.
- Este reporte técnico en sí mismo es un aporte científico, ya que documenta de manera detallada el diseño, la implementación y los resultados de la metodología, sirviendo como una base reproducible para futuras investigaciones en el área.

CAPÍTULO 2

MARCO TEÓRICO

Para este proyecto se utilizarán diversas técnicas y métodos en las diferentes etapas del desarrollo, desde la obtención de información de las imágenes, pasando por la generación de mapas de profundidad densos, hasta la reconstrucción 3D final [14, 27].

2.1 Base de datos utilizada: SUN RGB-D

Para el entrenamiento y la validación de los modelos de reconstrucción, se utilizará el dataset SUN RGB-D [23]. Esta es una base de datos a gran escala, ampliamente reconocida en la investigación de visión por computadora, que contiene más de 10,000 imágenes RGB-D de escenas interiores diversas. Fue seleccionado por sus características principales:

- **Diversidad de Escenas:** Ofrece una amplia variedad de entornos interiores, lo que mejora la capacidad de generalización y la robustez del modelo de relleno de profundidad.
- **Datos Multimodales:** Proporciona imágenes a color (RGB) junto con sus correspondientes mapas de profundidad, capturados con sensores como Kinect v2 e Intel RealSense. Esto es fundamental para entrenar modelos que aprenden a correlacionar la información visual con la geométrica.

2.2 Preprocesamiento de Imágenes

Para asegurar un mejor entrenamiento del modelo utilizando estas imágenes, es necesario un preprocesamiento de las mismas. Se tienen dos objetivos en mente: primero, mejorar la calidad de la imagen y, segundo, estandarizar su formato y dimensiones. Este proceso se aplica tanto a las imágenes RGB como a los mapas de profundidad y estos métodos para ambos tipos de imágenes sean:

2.2.1 RGB-D:

- **Filtro Bilateral Vectorizado:** Es una técnica de suavizado de imágenes que tiene la ventaja de preservar los bordes nítidos [18]. A diferencia de otros filtros, pondera los píxeles no solo por su proximidad espacial, sino también por su similitud en la intensidad del color. Esto suaviza el ruido en áreas de color uniforme sin difuminar los contornos de los objetos, lo cual es vital para una reconstrucción precisa.
- **Shape from Shading (SFS):** Esta técnica permite inferir la geometría tridimensional a partir de las variaciones de iluminación en una sola imagen 2D [32]. El algoritmo analiza cómo las sombras y brillos se relacionan con la orientación de la superficie para estimar su forma. Se usa para acentuar las estructuras volumétricas de la escena, proporcionando información geométrica adicional.

2.2.2 Imágenes de Profundidad:

- **Normalización de Profundidad:** Los sensores capturan la distancia en milímetros. Para que estos datos sean compatibles con los algoritmos de reconstrucción, los valores se convierten a metros dividiéndolos por 1000 y usando precisión de punto flotante.
- **Generación de Máscara:** Se crea una máscara binaria para identificar los píxeles no válidos en el mapa de profundidad. Esta máscara es crucial para que el modelo ignore estas regiones al calcular la pérdida durante el entrenamiento y para que las métricas de evaluación se centren únicamente en las regiones válidas [1].

2.3 Modelo para Relleno de Profundidad

Al obtener los mapas de profundidad de un sensor RGB-D, es común que existan espacios vacíos ("agujeros"). Esto ocurre por las limitaciones físicas del sensor, que falla en superficies reflectantes, transparentes o muy lejanas [1]. Estos vacíos son un obstáculo para la reconstrucción 3D. Para solventarlo, se utilizará un modelo basado en aprendizaje profundo enfocado en la completitud de profundidad (depth completion) [28].

2.3.1 Arquitectura Encoder-Decoder:

Se optará por una estrategia de *Transfer Learning* utilizando una arquitectura "Encoder-Decoder". El codificador se basará en redes convolucionales eficientes (como EfficientNet), las cuales utilizan el escalado compuesto (compound scaling) para equilibrar profundidad, ancho y resolución. El uso de bloques pre-entrenados permite aprovechar características visuales complejas aprendidas en grandes datasets, transfiriendo ese conocimiento a la tarea geométrica de completado de profundidad.

2.4 Reconstrucción 3D con Total Scene Understanding

Una vez que se obtiene un mapa de profundidad denso, el siguiente paso es la reconstrucción geométrica 3D. Este proceso se compone fundamentalmente de dos tareas que se explicarán a continuación:

- **Estimación Precisa de la Pose de la Cámara (Odometría Visual):** Este es el proceso de determinar la ubicación y orientación exactas de la cámara en cada instante [21]. Al rastrear cómo se mueve la cámara, el sistema puede alinear correctamente todos los mapas de profundidad en un único sistema de coordenadas global.
- **Fusión de Superficies:** Es el paso final donde toda la información de profundidad alineada se fusiona para crear un único y coherente modelo 3D. A menudo, esto utiliza una representación volumétrica como el **Truncated Signed Distance Function (TSDF)**, una cuadrícula que llena el espacio, donde cada vóxel almacena su distancia a la superficie más cercana [14].
- **Total Scene Understanding (TSU):** Este es un paradigma que va más allá de la simple geometría [2]. El objetivo es que el sistema no solo "reconstruya" el espacio, sino que "comprenda" los objetos que se encuentren dentro del entorno reconstruido con el modelo 3D geométrico. Aunque el TSU completo está fuera del alcance de este proyecto, nuestro método de **FusionVision** [6] es un primer paso en esta dirección, ya que busca segmentar objetos específicos durante el proceso de fusión.

CAPÍTULO 3

ESTADO DEL ARTE

La reconstrucción 3D de escenas interiores a partir de cámaras RGB-D (Rojo, Verde, Azul y Profundidad) es un campo de investigación diverso en la visión por computadora. Los estudios abordan los desafíos clave del proceso, que van desde la adquisición y el procesamiento de datos ruidosos hasta la estimación precisa de la pose de la cámara y la fusión coherente de múltiples vistas para generar un modelo tridimensional final. El objetivo es superar las limitaciones inherentes de los sensores de bajo costo, como el ruido en los mapas de profundidad y la incapacidad para medir superficies reflectantes o transparentes [1].

Este ruido se presenta como agujeros o datos faltantes, el cual es un problema común cuando el sensor infrarrojo de la cámara interactúa con materiales brillantes, transparentes o superficies muy lejanas.

La estimación precisa de la pose de la cámara es un pilar fundamental, ya que pequeños errores de seguimiento pueden acumularse y provocar un efecto de "*drift*", resultando en des-alineaciones, duplicaciones o inconsistencias en el modelo 3D final.

Para resolver estos problemas, el campo ha evolucionado desde enfoques algorítmicos clásicos hacia la integración de técnicas de aprendizaje profundo, *deep learning*. Estos modelos modernos son capaces de inferir información geométrica a partir de las imágenes a color, permitiendo rellenar los vacíos dejados por el sensor de profundidad y mejorando la robustez en la estimación de la pose.

El flujo de trabajo para la reconstrucción 3D de alta calidad generalmente se compone de las siguientes etapas:

- Procesamiento y relleno de datos de profundidad: Mejorar la calidad de los mapas de profundidad eliminando el ruido y rellenando las áreas faltantes.
- Estimación de la pose de la cámara: Estimar con precisión la posición y orientación de la cámara en cada fotograma para alinear las diferentes vistas.
- Fusión y reconstrucción de superficies: Integrar los datos de profundidad alineados de múltiples vistas en un único modelo 3D coherente.

3.1 Análisis de trabajos relacionados

El relleno de profundidad de las imágenes RGB-D es una parte esencial para el proyecto, especialmente para poder realizar la reconstrucción de una manera rentable. Para solucionar esto el estudio "*Deep Depth Densification*" [4] usó una arquitectura de codificador-decodificador basada en "DenseNet" de múltiples escalas. En el caso del entrenamiento los mapas de profundidad dispersos (S1 y S2) se inyectan a múltiples escalas para mantener la información de profundidad en toda la red y la red predice un mapa de profundidad residual, que se añade a S1 para generar la salida de profundidad densa final. Tomando en cuenta que se obtuvo un rendimiento comparable al de los sensores de profundidad de consumo (error de 1% con una escala de 16×16), su método de entrenamiento será una avenida prometedora para tomar en cuenta.

El siguiente paso después de la estimación de la profundidad es la estimación de la cámara para poder hacer la reconstrucción de manera precisa. Para esto leímos la metodología de un estudio [26], el cual propone "Dense Scene Matching" (DSM), un nuevo método independiente de la escena para la estimación de la pose de la cámara a partir de imágenes RGB. A diferencia de los enfoques tradicionales específicos de la escena, "DSM" construye un volumen de costos entre una imagen de consulta y una escena 3D para predecir mapas de coordenadas densos, lo que permite la generalización a escenas arbitrarias sin necesidad de volver a entrenar. La cual logra una precisión de última generación en interiores (7 escenas), superando a "SAnet" (*Scene Agnostic Network*) [30] entre un 1.6 y un 16% en precisión en todas las secuencias.

En cuestión de las reconstrucciones una vez teniendo las profundidades completas, un estudio compara diferentes maneras de como realizar este proceso [14]. En cuanto a la estimación de la pose de la cámara, se comparan métodos basados en **ICP** (*Iterative Closest Point*), basados en características e híbridos. En la reconstrucción como tal, se revisan métodos de Fusión (basada en volumen, basada en superficie), optimización (eliminación de ruido, refinamiento) y finalización (a nivel de objeto/escena). Finalmente usando *Benchmarks* (datasets de referencia) como **ICL-NUIM** y **TUM RGB-D** que muestran que *BundleFusion* [5] y *UncertaintyAware* [25] tienen el mejor rendimiento en precisión de seguimiento y reconstrucción de superficies.

Otro estudio [15] usó cámaras de profundidad para el consumidor como la "Kinect", el sistema divide la escena en segmentos lógicos según el contenido (como objetos o paredes) en lugar de un número fijo de fotogramas, lo que mejora la precisión de la alineación. Estos segmentos se unen mediante una combinación de ajuste fino local (ICP). Su método supera las técnicas existentes en precisión manejando de manera eficiente los desafíos de un entorno real, lo que lo hace práctico para aplicaciones como la robótica y la realidad virtual.

Tabla 1: Estudios Relacionados (Parte 1: Modelado CAD y Holografía)

Título	Metodología	Dataset	Resultados	Limitaciones
eCAD-Net: Editable Parametric CAD Models Reconstruction from Dumb B-Rep Models Using Deep Neural Networks	Framework basado en redes neuronales profundas (CNN + Transformer) que reconstruye secuencias de operaciones sketch-extrude a partir de modelos B-Rep "tontos"	Dataset limpiado de 10,471 modelos CAD (derivado de DeepCAD y ABC)	ACC_t: 97.70%, ACC_p: 89.12%, V_r: 96.48%, SD: 88.76%. Supera a DC-Point, DC-Graph, UV-32 y G-Sequence	Limitado a operaciones sketch-extrude. No maneja features como fillets o revoluciones. Las secuencias predichas pueden tener inconsistencias.
HoloForkNet: Digital Hologram Reconstruction via Multibranch Neural Network	Multibranch U-Net para reconstrucción de hologramas digitales inline, eliminando ruido óptico y órdenes de difracción no deseados.	Hologramas generados por computadora y registrados ópticamente (hasta 2048×2048 píxeles). Escenas con 2 a 20 planos.	SSIM (Índice de Similitud Estructural): 0.94 (8 planos), CC (Coeficiente de Correlación): 0.90 ± 0.09 . Reconstrucción de alta calidad.	Calidad disminuye con muchos planos u objetos. Tiempo de entrenamiento aumenta con planos adicionales. No optimizado para objetos muy superpuestos.

Continued on next page

Tabla 1: Estudios Relacionados (Parte 1: Modelado CAD y Holografía) (Continued)

Título	Metodología	Dataset	Resultados	Limitaciones
Approximating Procedural Models of 3D Shapes with Neural Networks	Arquitectura NNProc basada en Autoencoder con espacios latentes alineados para mapeo directo e inverso de modelos procedimentales.	Datos generados automáticamente a partir de modelos procedimentales (Python y Geometry Nodes de Blender). 3000-10000 formas por categoría. Voxelizadas a 64^3 .	Chamfer distance: 0.0001–0.0025. Reconstrucción desde imágenes: 0.0072–0.0452. Supera a baseline de optimización (COBYQA).	Limitado a modelos con pocos parámetros. Calidad afectada por detalles finos (voxels). Dependiente de poses de cámara en reconstrucción desde imágenes.

Tabla 2: Estudios Relacionados (Parte 2: Reconstrucción de Escenas Interiores)

Título	Metodología	Dataset	Resultados	Limitaciones
High-quality indoor scene 3D reconstruction with RGB-D cameras: A brief review	Revisión de métodos de procesamiento de profundidad, estimación de poses (ICP, características, híbridos) y reconstrucción de superficies (fusión, optimización, finalización).	Múltiples datasets: TUM RGB-D, ICL-NUIM, ScanNet, Matterport3D, Replica, etc. Evaluación con ATE (Error Absoluto de Trayectoria) RMSE (Error Cuadrático Medio).	BundleFusion: ATE RMSE 15 mm; UncertaintyAware: mejor precisión en superficies (error mediano 4-6 mm). InfiTAM v3: más rápido (910 fps en GPU).	Limitado a entornos interiores. Calidad afectada por superficies reflectantes / transparentes. Dependencia de hardware e iluminación. Métodos de <i>deep learning</i> requieren grandes datasets.

Continued on next page

Tabla 2: Estudios Relacionados (Parte 2: Reconstrucción de Escenas Interiores) (Continued)

Título	Metodología	Dataset	Resultados	Limitaciones
3D Reconstruction of Simple Buildings from Point Clouds Using Neural Networks (ConvPoint)	Red neuronal (ConvPoint) para segmentación de caras del techo y módulos PointNet para predecir pendientes. Reconstrucción mediante half-space modeling.	RoofN3D: 118,000 edificios simples. Subconjunto de 67,383 edificios con 100–350 puntos.	IoU (Intersección sobre Unión): 80.27%, MAE (Error Absoluto Medio) pendiente: 1.8°, Precisión caras: 95.73%.	Limitado a edificios simples con techos convexos (hasta 4 caras). Depende de una huella rectangular predefinida. No incluye techos planos.
FusionVision: A Comprehensive Approach of 3D Object Reconstruction	Pipeline que combina YOLO (<i>You Only Look Once</i>) para detección 2D, FastSAM (<i>Fast Segment Anything Model</i>) para segmentación, y alineación RGB-D para reconstrucción 3D.	Dataset propio de 100 imágenes (vaso, botella, etc.) capturadas con Intel RealSense D435i.	YOLO : mAP50 97.92%. FastSAM : IoU 0.94. Tasa de frames: 27.3 fps en GPU RTX 2080 Ti. Eliminación de 85% de ruido.	Limitado a objetos pequeños y escenas interiores. Depende de la calibración RGB-D. Requiere GPU para tiempo real. No evalúa oclusión severa.

Continued on next page

Tabla 2: Estudios Relacionados (Parte 2: Reconstrucción de Escenas Interiores) (Continued)

Título	Metodología	Dataset	Resultados	Limitaciones
Displacement Measurement and 3D Reconstruction of Segmental Retaining Wall...	Combina visión estereoscópica para 3D y CNNs (U-Net , FPN - <i>Feature Pyramid Network</i> , PSPNet - <i>Pyramid Scene Parsing Network</i>) para segmentación de bloques.	Experimentos de laboratorio (bloques de yeso) y campo (muro real). Validación con sensores láser.	Segmentación: F1-score 0.910–0.965. Reconstrucción 3D: precisión 95.2–98.6%. Error desplazamiento: 0.7–2.3 mm (lab).	Limitado a texturas uniformes. Requiere calibración precisa. Sensible a vibraciones. No evalúa desplazamientos complejos.

Tabla 3: Estudios Relacionados (Parte 3: SLAM y Componentes de Reconstrucción)

Título	Metodología	Dataset	Resultados	Limitaciones
Learning Camera Localization via Dense Scene Matching	Método de localización agnóstico a escena (DSM) mediante un volumen de coste entre la imagen de consulta y escenas de referencia. Esquema coarse-to-fine con PnP (<i>Perspective-n-Point</i>) + RANSAC (<i>Random Sample Consensus</i>).	Entrenado en ScanNet. Evaluado en 7Scenes (interior) y Cambridge Landmarks (exterior). Usa ResNet50-FPN.	Precisión en 7Scenes: 0.68–1.33° (rot), 0.01–0.05m (trans). Supera a SANet. Velocidad: 0.21s por frame.	Requiere imágenes de referencia con coordenadas 3D. Sensible a la calidad de la recuperación de imágenes. No funciona en escenas sin solapamiento visual con la BBDD.

Continued on next page

3.1. ANÁLISIS DE TRABAJOS RELACIONADOS

Tabla 3: Estudios Relacionados (Parte 3: SLAM y Componentes de Reconstrucción)
(Continued)

Título	Metodología	Dataset	Resultados	Limitaciones
Uncertainty-Aware Normal-Guided Gaussian Splatting...	UNG-GS: Framework basado en 3D Gaussian Splatting con un campo de incertidumbre espacial (SUF) explícito. Incluye renderizado de profundidad y normales.	DTU, Tanks y Temples (TnT), Mip-NeRF 360.	Mejora CD en DTU (0.62 mm), F1-score en TnT (0.39). Supera a 2DGS, GOF, RaDe-GS, PGSR.	Dificultades con superficies reflectantes o transparentes. Depende de COLMAP para nube de puntos inicial.
A Survey of Visual SLAM Methods	Revisión de métodos V-SLAM (<i>Visual SLAM</i>), clasificados por sensor (monocular, estéreo, RGB-D) y enfoque (directo, características, semántico).	KITTI, EuRoC, TUM-RGBD, ICL-NUIM, ETH3D, TartanAir, InteriorNet, etc.	Análisis comparativo de métodos, métricas (ATE, RPE), tendencias, desafíos y direcciones futuras.	No propone un método nuevo. Se enfoca en revisión y comparativa. No incluye experimentos propios.

El análisis de los trabajos presentados en las Tablas 1 y 2 revela una clara tendencia hacia el uso de redes neuronales profundas como la principal herramienta para abordar los desafíos de la reconstrucción 3D. Sin embargo, las arquitecturas y enfoques específicos varían significativamente según la naturaleza del problema. A continuación, se describen los grupos de metodologías más relevantes identificados en la literatura.

Arquitecturas Neuronales para la Interpretación Geométrica: Una gran parte de los estudios emplea arquitecturas de redes neuronales especializadas para procesar datos geométricos. Por ejemplo, se observan modelos que combinan Redes Neuronales Convolucionales (CNN) con Transformers para reconstruir secuencias de operaciones en modelos CAD [16], aprovechando la capacidad de las CNN para extraer características locales y de los Transformers para entender relaciones secuenciales.

Pipelines Basados en Comprensión Semántica de la Escena: Un enfoque cada vez más popular consiste en no tratar la reconstrucción como un problema puramente geométrico, sino integrarle una capa de "comprensión semántica". El sistema "FusionVision" [6] es un claro ejemplo de esta tendencia, ya que crea un *pipeline* que primero detecta objetos en 2D con modelos como "YOLO" y luego los segmenta con "FastSAM". Al tener identificados y delimitados los objetos de la escena, la reconstrucción 3D resulta más precisa y segmentada, lo cual es fundamental para aplicaciones de robótica o realidad aumentada donde la interacción con objetos específicos es necesaria.




Figura 1: Relación entre la literatura utilizada

3.2 Conclusión del análisis de la literatura

Se ha podido observar a lo largo del análisis de la literatura y el estado del arte que existe una constante evolución. Esto se debe principalmente a la creación e implementación de nuevas tecnologías, pasando de algoritmos tradicionales a métodos enfocados en el aprendizaje máquina. Estos últimos han llegado para dar una alternativa que hace viables a los sensores de bajo costo sin la necesidad de utilizar equipo

de alta gama, buscando solucionar la generación de mapas de profundidad con ruido y pérdida de datos, sobre todo con superficies irregulares [1].

Para realizar un análisis crítico de la literatura, fue necesario separar el problema en las tres etapas identificadas: (1) el preprocesamiento y relleno de datos de profundidad, (2) la estimación de la posición de la cámara y (3) la fusión de vistas para el modelado de la superficie.

Sin embargo, este análisis revela limitaciones clave que motivan la propuesta de este proyecto. En la estimación de pose, aunque "Dense Scene Matching" (DSM) [26] es potente, su **limitación** (identificada en la Tabla 3) es su dependencia de una base de datos de escenas de referencia con coordenadas 3D, lo que lo hace poco práctico para una reconstrucción en tiempo real de un entorno nuevo. Por otro lado, sistemas integrales de alta precisión como *BundleFusion* [5] (mencionado en [14]) son conocidos por su alta carga computacional.

La **principal brecha (gap) identificada** es la falta de un *pipeline* que integre de forma eficiente un relleno de profundidad robusto (para compensar el ruido del sensor) con una estimación de pose semántica que sea precisa pero computacionalmente accesible.

Por lo tanto, este proyecto identifica a **FusionVision** [6] como el **punto de partida metodológico** más relevante, debido a su novedosa integración de detección 2D (YOLO) y segmentación (FastSAM) en el *pipeline* de reconstrucción. Sin embargo, se propone abordar sus **limitaciones** identificadas (reportadas en la Tabla 2: "Limitado a objetos pequeños y escenas interiores" y "No evalúa escenas complejas o oclusión severa"). Esto se logrará integrando un módulo de relleno de profundidad más robusto (inspirado en [4]) como un paso de preprocesamiento explícito, y reemplazando su componente de alineación por un método de odometría visual más resiliente, para así escalar el método de objetos individuales a escenas interiores completas.

CAPÍTULO 4

METODOLOGÍA

La metodología empleada en este proyecto sigue una secuencia de pasos, que se resume visualmente en el diagrama de flujo presentado en la Figura 2. Describe el flujo de trabajo completo de nuestro sistema de reconstrucción 3D, comenzando con la adquisición inicial de datos mediante una cámara RGB-D (base de datos SUN RGB-D). Tras la fase de adquisición, los datos brutos se someten a una etapa crítica de preprocesamiento para filtrar el ruido y alinear la información de profundidad y color. El núcleo del proceso es la fase de reconstrucción 3D, donde se aplican técnicas de estimación de la pose de la cámara, registro de nubes de puntos y mallado de superficies para construir el modelo geométrico. Finalmente, el modelo 3D resultante se somete a una evaluación mediante puntos de referencia especializados para evaluar su precisión y fidelidad. Este diagrama de flujo sirve como guía general, ilustrando la progresión lógica que se detallará en las secciones posteriores.




Figura 2: Diagrama de proceso de metodología.

4.1 Entorno de Desarrollo

El proyecto se desarrollará utilizando el siguiente stack de software:

- Hardware de Cómputo: GPU NVIDIA (RTX 3080 ti) para la inferencia en tiempo real. Sera necesario por la carga computacional requerida para ejecu-

tar simultáneamente la red de completado de profundidad y los modelos de segmentación semántica durante el bucle de reconstrucción.

- Lenguaje: Python 3.12
- Framework de Deep Learning: TensorFlow/Keras para construir y entrenar el modelo Encoder-Decoder.
- Procesamiento 3D: Librería Open3D (o PCL) para la manipulación de nubes de puntos, implementación de ICP y fusión TSDF.
- Utilidades: OpenCV para el filtrado bilateral y NumPy para operaciones numéricas.

4.2 Arquitectura del Sistema Propuesto

El sistema propuesto funciona como un *pipeline* modular secuencial, diseñado para integrar metodologías que, en la literatura, suelen tratarse por separado.

Esta arquitectura híbrida unifica tres corrientes de investigación principales para resolver las limitaciones de los sensores de bajo costo:

- **Preprocesamiento Inteligente:** Se adaptan arquitecturas de redes neuronales (inspiradas en trabajos de densificación profunda) para reparar la información geométrica incompleta del sensor.
- **Filtrado Semántico:** Se incorporan modelos de detección y segmentación de objetos (basados en el enfoque de *FusionVision*) para discriminar entre elementos estáticos y dinámicos.
- **Fusión Geométrica:** Se emplean algoritmos de odometría híbrida y reconstrucción volumétrica para alinear espacialmente los datos procesados.

4.3 Obtención de imágenes RGB

Obtención de imágenes con cámaras RGB-D: Este método proyecta un patrón de luz infrarroja sobre la escena y estima la profundidad. Se obtendrán las imágenes RGB para realizar el entrenamiento del modelo mediante datasets confiables de relevancia académica. Se puede apreciar en la Figura 3 como se vería la obtención de la profundidad mediante una imagen RGB



Figura 3: Ejemplo de obtención de la profundidad. [22]

El entrenamiento del modelo que vamos utilizar para el relleno de profundidad y posteriormente la reconstrucción 3D que es el resultado del proyecto, se hará con el dataset de SUN RGB-D esta es la mejor de las opciones debido a que es un dataset muy utilizado para los proyectos que involucren visión por computadora, debido a la gran cantidad de imágenes que tiene una cantidad de imágenes muy grande y mucha diversidad entre ellas además de que cuenta con una gran ventaja es que tiene las secciones de cada imagen correctamente etiquetadas haciendo diferenciación entre los objetos tales como "sillas", "mesas", etc. lo que ayuda en gran manera a que el entrenamiento se haga de manera eficiente y tenga un mejor desempeño a la hora de evaluar el modelo, en la figura 5, se ve un ejemplo de como se ven las imágenes de este dataset



Figura 4: Ejemplo SUN RGB-D [22]

Posteriormente debemos de obtener imágenes para poder evaluar el desempeño del modelo, además de que estas tienen que ser obtenidas de una cámara de baja gama debido a que parte del objetivo del modelo, que las imágenes que se utilicen obtener para hacer la reconstrucción deban ser con un equipo de computo de bajo costo a continuación se muestra una tabla con las opciones contempladas para la obtención de estas imágenes

Tabla 4: Comparativa de Cámaras RGB-D Accesibles para Investigación

Nombre	Precio (Aprox.)	Ventajas Principales
Intel RealSense D435i	\$200 - \$300 USD	• Mejor soporte: Excelente SDK (librealsense) con soporte nativo para Python y Ubuntu. • IMU Integrada: Crucial para tu objetivo de "estimación de pose". • Moderna: Soporte activo y gran comunidad.
Microsoft Kinect v2	\$30 - \$60 USD (Usada)	• Costo más bajo: Opción más económica (mercado de segunda mano). • Datos de calidad: Buena tecnología ToF (Tiempo de Vuelo). • Desventaja: Descontinuada, requiere adaptador y configuración compleja en Linux ('libfreenect2').
Orbbec Gemini 335 / 335L	\$200 - \$230 USD	• Tecnología Active Stereo IR: Ideal para interiores sin textura y exteriores, superior a la luz estructurada clásica.. • IMU Integrada: Incluye giroscopio y acelerómetro, esencial para robustecer la odometría visual y evitar el "drift". • Soporte: SDK moderno con soporte nativo para ROS 2 y NVIDIA Jetson.

4.4 Filtrado del ruido

Utilizar un método filtrado bilateral tradicional el cual permita suavizar las imágenes conservando los bordes mediante una combinación no lineal de valores de imágenes cercanas. Funciona promediando los valores de los píxeles en función de su proximidad

espacial y similitud de intensidad.

Este método es bastante correcto para lo que se busca en este proyecto, debido a que precisamente el hecho de que ayude a marcar y conservar los bordes, esto lo hace asignando pesos más grandes a los píxeles que son similares entre ellos, haciendo que de esta manera, se puedan suavizar las imágenes sin sacrificar las diferencias entre los objetos, por ejemplo una mesa en medio de un cuarto al hacer el suavizado de las imágenes, lo píxeles que son de la categoría de mesa, se diferencian del resto de cuarto teniendo una diferente intensidad entre cada píxel, haciendo que se puedan agrupar los píxeles marcando entonces los borde de cada objeto.



Figura 5: Comparación de un ejemplo antes y después de aplicar el filtro [22]


En estas imágenes podemos ver el cambio entre ellas, ya que la de la izquierda es antes de aplicar el filtro en contraste a la de la derecha donde ya se suavizaron los bordes por lo que se puede apreciar un efecto de suavizado, sin embargo se ve que no se difuminan los bordes lo cual nos interesa mucho ya que es de gran importancia que se puedan diferenciar los diferentes objetos de las imágenes

4.5 Relleno de profundidad

Para garantizar la convergencia del modelo y la robustez en la extracción de características geométricas, se implementará una arquitectura Encoder-Decoder basada en Transfer Learning.

- Encoder: Se usara EfficientNet-B0, esta arquitectura ha demostrado una eficiencia superior con respecto a precisión-parámetros en comparacion con modelos como Resnet. El uso de pesos pre-entrenados permite al modelo aprovechar filtros de bajo nivel (bordes, esquinas y texturas) ya optimizados, lo cual es crítico dado el tamaño limitado del dataset SUN RGB-D.
- Decoder: La etapa de decodificación utilizará capas "ConvTranspose2D" combinadas con bloques de atención. Se diseñará una estructura tipo "U-Net", donde se usan Conexiones de Salto (Skip-Connections). Esto es fundamental para recuperar los detalles finos y los bordes nítidos de los objetos que suelen perderse en las capas profundas de la red.

- Estrategia de Entrenamiento: Se aplicará una técnica de “Fine-tuning”, que consiste en congelar inicialmente las primeras capas del Encoder para preservar características básicas y reentrenar solo las capas profundas y el Decoder para que se adapten específicamente a la tarea de finalización de profundidad.



(a) Imagen RGB de cámara (b) Profundidad parcial (c) Profundidad rellenada

Figura 6: Comparación de las tres etapas [22]

4.6 Validación del Modelo de Profundidad

Antes de integrarlo al pipeline de reconstrucción, el modelo Encoder-Decoder será evaluado cuantitativamente en el conjunto de test de SUN RGB-D. Se comparará la profundidad predicha contra el "ground truth" usando las siguientes métricas estándar:

- RMSE (Root Mean Square Error): Error cuadrático medio.
- MAE (Mean Absolute Error): Error absoluto medio.
- Accuracy (δ): Porcentaje de píxeles donde el error relativo ($\frac{\text{pred}}{\text{truth}}$) es menor a un umbral (ejemplo, $\delta < 1.25$).

4.7 Calibración de la cámara

La calibración es un paso fundamental para asegurar la precisión métrica de la reconstrucción. El proceso se divide en dos componentes:

- Calibración Intrínseca: Define las características ópticas internas (distancia focal, punto principal y coeficientes de distorsión) que permiten proyectar correctamente los puntos 3D en el plano de imagen 2D.
- Calibración Extrínseca: Determina la transformación rígida (rotación y traslación) entre el sensor RGB y el sensor de profundidad, permitiendo la alineación precisa de la información de color sobre la geometría.

4.8 Procesamiento Semántico y Segmentación de Instancias

Para cumplir con el objetivo de "Total Scene Understanding" y asegurar la robustez del sistema en entornos dinámicos, se integra un módulo de procesamiento semántico que opera en paralelo a la estimación de profundidad. Este proceso necesitara el uso de la una GPU de alta gama, ya que permite ejecutar inferencia de múltiples modelos profundos en tiempo real

Cada fotograma constara de dos etapas:

- **Detección de Objetos:** Se implementará el modelo YOLOv11 para identificar y clasificar los objetos presentes en la escena (sillas, mesas, personas, etc). Esta etapa genera las cajas delimitadoras y las etiquetas de clase necesarias para la comprensión semántica.
- **Segmentación de Instancias:** A partir de las detecciones, se utilizará el modelo FastSAM (Segment Anything Model) para generar máscaras binarias precisas a nivel de píxel.

El sistema identificará clases de objetos dinámicos, como personas, y generará una "máscara de ignorado", asegurando que estos elementos no sean utilizados como puntos de referencia para el rastreo de la cámara.

4.9 Reconstrucción de superficies y Fusión Semántica

La reconstrucción se realizará fotograma a fotograma, integrando la información geométrica densificada con los datos semánticos obtenidos en la sección anterior Para cada nuevo fotograma:

- (1) **Estimación de Pose Semántica:** La posición de la cámara se calculará alineando la nube de puntos del fotograma actual con el modelo global anterior utilizando el algoritmo ICP, este algoritmo recibirá como entrada las máscaras semánticas generadas en el paso anterior.
- (2) **Fusión Volumétrica:** La integración de los datos se realizará mediante una "Función de Distancia Signada Truncada" (TSDF) Cada vóxel del volumen global almacenará no solo la distancia a la superficie y el color RGB, sino también la etiqueta de clase (semántica) más probable acumulada de las predicciones de YOLOv11.
- (3) **Generación de Malla:** Se extraerá la "iso-superficie" cero del volumen para generar una malla 3D coherente. El resultado será un modelo geoméricamente denso donde cada polígono posee atributos de clasificación, permitiendo la interacción y análisis del entorno reconstruido.

4.10 Evaluación de resultados

Para garantizar la validez de la reconstrucción, el sistema se someterá a una evaluación rigurosa dividida en tres dimensiones: precisión de la trayectoria (Odometría), calidad de la reconstrucción (Geometría) y desempeño del filtrado (Semántica).

4.10.1 Métricas de Trayectoria y Odometría (SLAM)

Estas métricas son para validar la hipótesis de que el "filtrado semántico" reduce la deriva (drift). Se utilizarán las definiciones estándar del benchmark TUM RGB-D [24]:

- **Error Absoluto de Trayectoria (ATE - Absolute Trajectory Error):** Mide la consistencia global de la reconstrucción. Calcula la diferencia euclidiana directa entre la trayectoria estimada por el sistema y la trayectoria real (ground truth) proporcionada por los sistemas de captura de movimiento del dataset. Un ATE bajo indica que el "Gemelo Digital" es dimensionalmente fiel a la habitación real.
- **Error de Pose Relativa (RPE - Relative Pose Error):** Mide la exactitud local (fotograma a fotograma). Cuantifica la deriva en la traslación y rotación entre pares consecutivos de imágenes. Esta métrica es fundamental para evaluar la estabilidad del algoritmo Semantic-ICP propuesto.

4.10.2 Métricas de Evaluación Semántica

Dado que se se tiene un módulo de segmentación (YOLOv11/FastSAM) para filtrar objetos dinámicos, es necesario validar su eficacia.

- **IoU (Intersection over Union):** Mide la superposición entre la máscara de segmentación generada y la anotación real del objeto. Un "IoU" alto asegura que el sistema está identificando correctamente qué píxeles son "dinámicos" y deben ignorarse, validando así la etapa de preprocesamiento semántico.

4.10.3 Métricas de Evaluación de la reconstrucción

- **RMSE (Root Mean Square Error):** Se utilizará tanto para evaluar el modelo de completado de profundidad (comparando el mapa de profundidad predicho vs. real) como para la nube de puntos final. Penaliza los errores grandes, siendo un indicador sensible para detectar deformaciones en la estructura.
- **Precisión (Accuracy):** Cuantifica la distancia media de los puntos del modelo reconstruido hacia la superficie del modelo de referencia.
- **Complejidad (Completeness):** Mide qué porcentaje de la superficie de la escena real ha sido capturada exitosamente en el modelo digital. Esto es vital para determinar si el sistema es capaz de reconstruir áreas difíciles (esquinas oscuras, superficies brillantes).

4.11 Cronograma

Se incluye un cronograma en el presente documento, el cual funge como una herramienta estratégica para la planificación y gestión del proyecto.

Su propósito principal es demostrar la viabilidad del trabajo al desglosar el objetivo general en fases secuenciales y lógicas, asignando tiempos realistas para cada una, desde la adquisición de datos hasta la evaluación final de los resultados. El diagrama detalla la secuencia de las cinco fases principales, asignando responsabilidades y marcando los hitos clave para la entrega.




Figura 7: Cronograma del proyecto

4.11.1 Actividades asignadas en cada parte:

Fase 1: Investigación y Planificación

- Revisión bibliográfica de métodos RGB-D.
- Identificación de técnicas de reconstrucción 3D.
- Selección de herramientas y datasets.
- Planificación del modelo experimental

Fase 2: Preprocesamiento y Profundidad

- Adquisición de imágenes RGB-D.
- Limpieza y alineamiento de datos.
- Generación y normalización de mapas de profundidad.
- Implementación de relleno de profundidad (depth completion).

Fase 3: Calibración, Pose e Identificación

- Calibración intrínseca y extrínseca de cámaras.

- Estimación de pose de cámara (PnP / Bundle Adjustment).
- Detección y emparejamiento de características.
- Validación de precisión de la estimación de pose.

Fase 4: Reconstrucción y Evaluación

- Integración de vistas múltiples.
- Generación de nubes de puntos y mallas.
- Comparación con ground truth (métricas cuantitativas). Evaluación visual y refinamiento del modelo 3D.
- Evaluación visual y refinamiento del modelo 3D..

Fase 5: Documentación Final

- Redacción del informe técnico.
- Elaboración de resultados y conclusiones.
- Revisión y presentación final.

CAPÍTULO 5

RESULTADOS

5.0.1 Modelo de Profundidad

El Pipeline de Datos

Antes de que la red neuronal pueda aprender, los datos crudos del sensor deben ser transformados en tensores matemáticos.

- **Generación del Tensor de 5 Canales:** El modelo no procesa imágenes por separado. El cargador de datos fusiona la imagen RGB (normalizada entre 0 y 1), el mapa de profundidad crudo (*Raw Depth*) y la máscara binaria en un solo bloque tridimensional (*Tensor*) de forma (5, 480, 640). Esto obliga a la red a analizar la geometría y el color simultáneamente.
- **Recorte Físico:** Se implementó un límite máximo de profundidad de 8.0 metros. Cualquier valor por encima de este umbral se recorta a 8.0. Esto es vital para estabilizar el entrenamiento, evitando que valores atípicos disparen los gradientes matemáticos y rompan la red.
- **Validación de Máscaras:** La máscara (valores 0 y 1) le indica explícitamente a la red neuronal qué píxeles son válidos en la entrada y cuáles son los "huecos" que debe aprender a rellenar.

Arquitectura del Modelo

El primer paso del proyecto fue implementar el modelo de reconstrucción de profundidad. Esto se logró mediante una arquitectura codificador-decodificador con aprendizaje por transferencia. El codificador se basó en EfficientNet-B0 y el decodificador en una estructura U-Net con conexiones de salto. El modelo se entrenó con el conjunto de datos SUN RGB-D, que proporcionó una gran cantidad de imágenes RGB-D con sus correspondientes mapas de profundidad de referencia. La siguiente lista ofrece un breve resumen de la arquitectura del modelo:

- **Input Adapter:** Las redes pre-entrenadas tradicionales esperan imágenes estándar de 3 canales (R, G, B). Sin embargo, nuestro problema requiere 5 canales

simultáneos: RGB (3) + Profundidad Cruda (1) + Máscara de Vacíos (1). Hacemos uso de una capa convolucional inicial (*nn.Conv2d(5, 3)*) para transformar esta entrada de 5 canales a 3 canales, permitiendo así aprovechar los pesos pre-entrenados de EfficientNet-B0 sin modificaciones en su arquitectura.

- **Decoder - EfficientNet-B0:** En lugar de construir un codificador desde cero, aplicamos Aprendizaje por Transferencia usando EfficientNet-B0 con pesos de ImageNet. A medida que la imagen pasa por el codificador, reduce su tamaño espacial (resolución) pero aumenta su profundidad (canales). La imagen original de 480x640 se comprime hasta un tamaño de 15x20 con 1280 canales (features.8). En este punto, la red ha perdido casi toda la información espacial fina, pero tiene una comprensión semántica altísima de la escena.
- **Skip Connections:** Usamos *create_feature_extractor* para "clonar" la información en cinco etapas distintas del codificador (a escalas de 1/2, 1/4, 1/8, 1/16). Esto permite que la red recupere los detalles finos y la geometría exacta de los objetos.
- **Decoder:** El decodificador toma el mapa hipercomprimido (15x20) y lo pasa por 5 bloques de expansión. Cada bloque hace dos cosas:
 - Upsampling Bilineal (*nn.Upsample*).
 - Concatenación (*torch.cat*): Pega la información que viene de la conexión puente correspondiente.
 - Convoluciones (*_block*): Aplica convoluciones, Normalización por Lotes (Batch-Norm) y activación ReLU para fusionar el contexto semántico con el detalle espacial.
- **Salida Final:** Una última convolución reduce los canales a 1 (el mapa de profundidad). Se aplica una función de activación ReLU para imponer una restricción física fundamental, las distancias nunca pueden ser negativas.

El Ciclo de Entrenamiento

- **Optimizador (Adam):** Se utilizó el optimizador "Adam" con una tasa de aprendizaje inicial de 1e-4. Adam es el estándar en visión computacional porque ajusta dinámicamente el tamaño de los "pasos" que da la red al aprender, acelerando la convergencia.
- **Función de Pérdida (MSELoss):** Durante las 80 épocas, la red se optimizó minimizando el "Error Cuadrático Medio".
- **Procesamiento por Lotes (Batching):** Las imágenes no se analizan una por una, sino en lotes de 16. Esto paraleliza el trabajo en la tarjeta gráfica y estabiliza la dirección del aprendizaje, promediando el error de varias imágenes antes de actualizar los pesos.

La Métrica de Decisión

En estimación de profundidad, buscar una exactitud milimétrica es imposible e innecesario.

- $\delta < 1.25$: Esta métrica mide el porcentaje de píxeles donde la relación entre la profundidad predicha y la real es menor a 1.25. En otras palabras, evalúa cuántos píxeles tienen una predicción que no se desvía más del 25 % de la profundidad real. Un valor alto en esta métrica indica que la mayoría de las predicciones están dentro de un rango aceptable de error.

Resultados del relleno de profundidad

Tabla 5: Comparativa de Eficiencia en la Reconstrucción de Profundidad (Arquitectura Efficient-UNet)

Métrica	Evaluación Global	Evaluación Solo Huecos (Inpainting)
MAE (Error Promedio)	0.07 m (7 cm)	0.22 m (22 cm)
RMSE (Error Cuadrático)	0.21 m	0.49 m
Precisión Fina ($\delta < 1.25$)	98.14%	91.47%

El Contraste entre Global y Zonas Ciegas.

- La Evaluación Global arroja números casi perfectos (98.14% de precisión y solo 7 cm de error) porque el modelo tiene la ventaja de usar los datos válidos que el sensor físico sí logró captar. Para la mayor parte de la imagen, la red solo tiene que mantener la información intacta.
- La Evaluación Solo Huecos aísla exclusivamente los píxeles donde el sensor falló y entregó un vacío (cero). En estas zonas, el modelo está completamente ciego respecto a la profundidad y debe deducir la distancia basándose únicamente en las texturas, iluminación y formas de la imagen RGB.

Error Absoluto Medio (MAE): La Precisión Física

- Al evaluar las zonas de fallo del sensor, el error promedio sube de 7 cm a 22 cm. Esto es completamente aceptable, ya que el modelo no tiene información directa sobre la profundidad en estas áreas. Un error de 22 cm en un entorno interior es razonable para aplicación de reconstrucción 3D.

Precisión Fina ($\delta < 1.25$): Este es el indicador definitivo de que la arquitectura Efficient-UNet está funcionando. Lograr que el 91.47% de las predicciones caigan dentro de un margen de error estricto (menor al 25% de la distancia real) puramente a través de inferencia visual demuestra que el modelo aprendió con éxito a correlacionar mapas de características de color con topología 3D.

Ejemplos Visuales




Figura 8: Rellenos estimados de base de datos. [22]

5.0.2 Segmentación de objetos

Para mejorar la comprensión semántica de la escena y facilitar la reconstrucción 3D de objetos específicos, se entrenó un modelo de segmentación basado en YOLOv11s (segmentación) utilizando el dataset SUN RGB-D. Este conjunto de datos proporciona imágenes RGB-D con anotaciones de segmentación a nivel de píxel para 17 clases de objetos comunes en interiores. Se utilizaron 5,599 imágenes para entrenamiento y 1,399 para validación, con una división de 85% y 15% respectivamente.

Configuración del entrenamiento

El modelo se entrenó durante 300 épocas con las siguientes configuraciones:

- **Modelo base:** YOLO11s-seg.pt (pesos pre-entrenados en COCO).

-
- **Tamaño de imagen:** 1024×1024 píxeles.
 - **Tamaño del lote (batch):** 64.
 - **Dispositivo:** GPU NVIDIA (device 0).
 - **Optimizador:** SGD con $lr_0=0.01$, $lrf=0.01$, $momentum=0.937$, $weight_decay=0.0005$.

Clases de segmentación

El dataset SUN RGB-D proporciona etiquetas para 17 categorías de objetos, las cuales se utilizaron para entrenar el modelo:

1. Cama (bed)
2. Silla (chair)
3. Mesa (table)
4. Sofá (sofa)
5. Escritorio (desk)
6. Cómoda (dresser)
7. Estantería (bookshelf)
8. Lámpara (lamp)
9. Almohada (pillow)
10. Fregadero (sink)
11. Bañera (bathtub)
12. Inodoro (toilet)
13. Caja (box)
14. Encimera (counter)
15. Refrigerador (refrigerator)
16. Televisor (tv)
17. Cortina (curtain)

Resultados de validación

El conjunto de validación constó de 700 imágenes con un total de 4,127 instancias de objetos. Las métricas de evaluación se calcularon tanto para la detección de cajas delimitadoras (Box) como para la segmentación de máscaras (Mask). La Tabla 6 muestra los resultados por clase, donde P denota precisión, R denota recall, y mAP50 y mAP50-95 son el promedio de precisión media con umbrales IoU de 0.5 y 0.5:0.95, respectivamente.


Tabla 6: Resultados de validación del modelo YOLO11s-seg en el conjunto de prueba de SUN RGB-D

Clase	Imágenes	Instancias	Box(P)	Box(R)	mAP50	mAP50-95	Mask(P)
all	700	4127	0.787	0.555	0.633	0.522	0.784
bed	473	2569	0.842	0.644	0.724	0.587	0.839
chair	111	193	0.772	0.523	0.614	0.546	0.737
table	224	720	0.718	0.375	0.438	0.342	0.713
sofa	67	108	0.811	0.648	0.738	0.503	0.824
lamp	101	229	0.848	0.515	0.551	0.434	0.856
toilet	32	52	0.857	0.673	0.754	0.689	0.858
refrigerator	42	56	0.659	0.321	0.436	0.383	0.662
tv	110	200	0.789	0.740	0.805	0.692	0.785


Los resultados muestran un desempeño destacado en clases como cama (mAP50=0.724), inodoro (mAP50=0.754) y televisor (mAP50=0.805), mientras que clases como mesa (mAP50=0.438) y refrigerador (mAP50=0.436) presentan un rendimiento menor, posiblemente debido a la variabilidad en sus formas y oclusiones en las escenas interiores. La precisión de las máscaras (Mask(P)) es consistentemente alta, superando el 0.7 en la mayoría de las clases, lo que indica que el modelo es capaz de delimitar con precisión los objetos segmentados.

Visualizaciones de segmentación


La Figura 9 muestra ejemplos cualitativos de la segmentación realizada por el modelo en imágenes del conjunto de validación. Cada imagen ilustra la capacidad del modelo para identificar y segmentar múltiples objetos dentro de una escena interior típica.




(a) Ejemplo 1



(b) Ejemplo 2



(c) Ejemplo 3



(d) Ejemplo 4

Figura 9: Ejemplos de segmentación de objetos en escenas interiores del dataset SUN RGB-D. Las máscaras coloreadas corresponden a diferentes clases de objetos detectados por el modelo YOLO11s-seg.

REFERENCIAS

- [1] Afzal Maken, F., Muthu, S., Nguyen, C., Sun, C., Tong, J., Wang, S., Tsuchida, R., Howard, D., Dunstall, S., & Petersson, L. (2025). Improving 3d reconstruction through rgb-d sensor noise modeling. *Sensors*, 25(3), 950.
- [2] Al-Saad, A.-M. M. R., Zhang, Y., Hu, H., & Chen, K. (2023). Towards total scene understanding. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, 4460–4469.
- [3] Cashman, E. (2021). The engineering essentials behind lidar. <https://www.electronicdesign.com/markets/automotive/article/21160813/onsemi-the-engineering-essentials-behind-lidar>
- [4] Chen, Z., Badrinarayanan, V., Drozdov, G., & Rabinovich, A. (2018). Estimating depth from rgb and sparse sensing. *Proceedings of the European Conference on Computer Vision (ECCV)*, 167–182.
- [5] Dai, A., Nießner, M., Zollhöfer, M., Izadi, S., & Theobalt, C. (2017). Bundle-fusion: Real-time globally consistent 3d reconstruction using on-the-fly surface reintegration. 36(4). <https://doi.org/10.1145/3072959.3054739>
- [6] El Ghazouali, S., Mhirit, Y., Oukhrid, A., Michelucci, U., & Nourira, H. (2024). Fusionvision: A comprehensive approach of 3d object reconstruction and segmentation from rgb-d cameras using yolo and fast segment anything. *Sensors*, 24(9), 2889.
- [7] Endres, F., Hess, J., Sturm, J., Cremers, D., & Burgard, W. (2014). 3-d mapping with an rgb-d camera. *IEEE Transactions on Robotics*, 30(1), 177–187. <https://doi.org/10.1109/TRO.2013.2279412>
- [8] Fuller, A., Fan, Z., Day, C., & Barlow, C. (2020). Digital twin: Enabling technologies, challenges and open research. *IEEE access*, 8, 108952–108971.
- [9] Gutiérrez-Ramos, D. V., & González-Gárate, J. A. (2023). Retos y oportunidades de la transformación digital para las pymes en México. *Ciencia*, 74(2), 50–57. <https://www.revistaciencia.amc.edu.mx/index.php/vol-74-num-2/194-retos-y-oportunidades-de-la-transformacion-digital-para-las-pymes-en-mexico>
- [10] Handa, A., Whelan, T., McDonald, J., & Davison, A. J. (2014). A benchmark for rgb-d visual odometry, 3d reconstruction and slam. *2014 IEEE International Conference on Robotics and Automation (ICRA)*, 1524–1531. <https://doi.org/10.1109/ICRA.2014.6907054>
- [11] Instituto Nacional de Estadística y Geografía (INEGI). (2019). Censos económicos 2019: Resultados oportunos [Fuente primaria de los datos sobre la demografía de los negocios en México, que indica que las MIPYMES constituyen más del 99% de

- las unidades económicas y generan la mayoría del empleo.]. <https://www.inegi.org.mx/programas/ce/2019/>
- [12] Kamran-Pishhesari, A., Moniri-Morad, A., & Sattarvand, J. (2024). Applications of 3d reconstruction in virtual reality-based teleoperation: A review in the mining industry. *Technologies*, 12(3). <https://doi.org/10.3390/technologies12030040>
 - [13] Karunaratne, T., Ajiero, I. R., Joseph, R., Farr, E., & Piroozfar, P. (2025). Evaluating the economic impact of digital twinning in the aec industry: A systematic review. *Buildings*, 15(14). <https://doi.org/10.3390/buildings15142583>
 - [14] Li, J., Gao, W., Wu, Y., Liu, Y., & Shen, Y. (2022). High-quality indoor scene 3d reconstruction with rgb-d cameras: A brief review. *Computational Visual Media*, 8(3), 369–393.
 - [15] Li, J.-W., Gao, W., & Wu, Y.-H. (2018). Elaborate scene reconstruction with a consumer depth camera. *International journal of automation and computing*, 15, 443–453.
 - [16] Lin, R., Ji, Y., Ding, W., Wu, T., Zhu, Y., & Jiang, M. (2025). A survey on deep learning in 3d cad reconstruction. *Applied Sciences*, 15(12). <https://doi.org/10.3390/app15126681>
 - [17] Lu, Y., Yu, H., Ni, W., & Song, L. (2023). 3d real-time human reconstruction with a single rgb-d camera. *Applied Intelligence*, 53(8), 8735–8745.
 - [18] Paris, S., & Durand, F. (2022). A survey on bilateral filtering. *Foundations and Trends® in Computer Graphics and Vision*, 13(1–2), 1–191.
 - [19] Qiu, D., Pang, J., Sun, W., & Yang, C. (2019). Deep end-to-end alignment and refinement for time-of-flight rgb-d module. *Proceedings of the ieee/cvf international conference on computer vision*, 9994–10003.
 - [20] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, 234–241.
 - [21] Sahili, A. R., Hassan, S., Sakhrieh, S. M., Mounsef, J., Maalouf, N., Arain, B., & Taha, T. (2023). A survey of visual slam methods. *IEEE Access*, 11, 139643–139677.
 - [22] Song, S., Lichtenberg, S. P., & Xiao, J. (2015a). Sun rgb-d: A rgb-d scene understanding benchmark suite. *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 567–576. <https://doi.org/10.1109/CVPR.2015.7298655>
 - [23] Song, S., Lichtenberg, S. P., & Xiao, J. (2015b). SUN RGB-D: A rich annotated 3d reconstruction dataset for indoor scene understanding. *Proceedings of the IEEE conference on computer vision and pattern recognition*, 5375–5383.
 - [24] Sturm, J., Engelhard, N., Endres, F., Burgard, W., & Cremers, D. (2012). A benchmark for the evaluation of rgb-d slam systems. *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, 573–580. <https://doi.org/10.1109/IROS.2012.6385773>
 - [25] Tan, Z., Chen, X., Zhang, J., Feng, L., & Hu, D. (2025). Uncertainty-aware normal-guided gaussian splatting for surface reconstruction from sparse image sequences. <https://arxiv.org/abs/2503.11172>

- [26] Tang, S., Tang, C., Huang, R., Zhu, S., & Tan, P. (2021). Learning camera localization via dense scene matching. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 1831–1841.
- [27] Tychola, K. A., Tsimperidis, I., & Papakostas, G. A. (2022). On 3d reconstruction using rgb-d cameras. *Digital*, 2(3), 401–421.
- [28] Wang, W., Lai, Z., Chen, J., Yuan, Z., & Wang, C. (2023). Deep learning for monocular depth completion: A survey and beyond. *Pattern Recognition*, 140, 109559.
- [29] Xue, J., Hou, X., & Zeng, Y. (2021). Review of image-based 3d reconstruction of building for automated construction progress monitoring. *Applied Sciences*, 11(17). <https://doi.org/10.3390/app11177840>
- [30] Yang, L., Bai, Z., Tang, C., Li, H., Furukawa, Y., & Tan, P. (2019). Sanet: Scene agnostic network for camera localization, 42–51. <https://doi.org/10.1109/ICCV.2019.00013>
- [31] Yunus, R., Li, Y., & Tombari, F. (2021). Manhattanslam: Robust planar tracking and mapping leveraging mixture of manhattan frames. *2021 IEEE International Conference on Robotics and Automation (ICRA)*, 6687–6693.
- [32] Zhang, H.-R., Li, Z.-Y., Zhang, R.-G., Li, D.-D., & Zhang, H. (2023). Deep shape from shading: A survey. *Computational Visual Media*, 9(2), 183–216.
- [33] Zhang, Y., Gibson, G. M., Hay, R., Bowman, R. W., Padgett, M. J., & Edgar, M. P. (2015). A fast 3d reconstruction system with a low-cost camera accessory. *Scientific reports*, 5(1), 10909.
- [34] Zhang, Z., Zhang, M., Chang, Y., Esche, S. K., & Chassapis, C. (2015). Real-time 3-d reconstruction for facilitating the development of game-based virtual laboratories. *2015 ASEE Annual Conference & Exposition*, 26–1305.