

Trabajo Terminal

Reconstrucción 3D de Escenas Interiores mediante una Cámara de Profundidad de Bajo Costo

Presentan

René Alejandro Santos Mora

Víctor Hugo Tecpa Cisneros

Asesores

Dr. Esau Eliezer Escobar Juárez

Dr. Ricardo Ramos Aguilar

TT2026-1_IA14

Tlaxcala, 2026



Planteamiento del Problema

- **Reconstrucción tridimensional de alta calidad:** Sirven como base para aplicaciones como la realidad virtual, los videojuegos y los simuladores de entrenamiento. Renderizar un interior en 3D cuesta entre 350 y 800 dólares.
- **Barrera de accesibilidad:** Los escáneres LiDAR profesionales ofrecen alta precisión pero su costo es prohibitivo. Los sensores económicos (Intel RealSense, Azure Kinect) producen reconstrucciones con ruido, oclusión y deriva considerable.
- **Fallos del sensor:** Las cámaras de profundidad infrarrojo fallan al interactuar con superficies reflectantes o transparentes, generando huecos o datos faltantes que comprometen la calidad del modelo 3D.
- **Desalineación RGB-D:** Los sistemas tradicionales que sincronizan color con profundidad presentan problemas de desalineación óptica cuando las condiciones de iluminación varían.
- **Propuesta:** Operar exclusivamente en el espectro infrarrojo nativo del sensor, integrando modelos de aprendizaje profundo (completado de profundidad + segmentación semántica) con odometría visual ICP y fusión volumétrica TSDF.

Evaluación: ICP RMSE (error de alineación local), Fitness (nivel de ajuste) y complejidad de malla para cuantificar la precisión geométrica del gemelo digital.

Objetivo General y Específicos

Objetivo General

Desarrollar un **pipeline de reconstrucción tridimensional de alta fidelidad** para entornos interiores, optimizado para el espectro infrarrojo, empleando hardware de bajo costo y técnicas avanzadas de aprendizaje profundo.

Objetivos Específicos

- 1 **Mejorar calidad de mapas de profundidad** mediante reducción medible del ruido y áreas faltantes con arquitectura Efficient-UNet.
- 2 **Estimar trayectoria local** de la cámara mediante esquema híbrido de odometría visual + refinamiento geométrico ICP punto-a-plano.
- 3 **Reconstruir superficies 3D coherentes** mediante fusión volumétrica TSDF de datos infrarrojos con segmentación semántica YOLO11x-seg y FastSAM.
- 4 **Evaluar desempeño del sistema** con métricas ICP RMSE, Fitness y complejidad de malla para cuantificar precisión local y calidad geométrica.

Hipótesis y Justificación

Hipótesis

La integración de **modelos de aprendizaje profundo** para reconstrucción de profundidad, en conjunto con un sistema de odometría visual, permite compensar las deficiencias ópticas y el ruido inherente a los **sensores infrarrojos de bajo costo**.

Se espera generar reconstrucciones tridimensionales con un **RMSE inferior a 2 cm**, evaluando la viabilidad de prescindir de equipos de alto costo.

Justificación

Compensación de deficiencias del hardware: Los sensores de bajo costo generan huecos y ruido. ICP puro falla cuando no hay suficientes puntos para emparejar. La integración de Efficient-UNet (rellena huecos) + YOLO (filtra dinámicos) + ICP (alinea) permite que el sistema funcione con datos de baja calidad.

Brecha en la literatura: Trabajos como FusionVision usan segmentación semántica pero solo para objetos pequeños. Deep Depth Densification resuelve el relleno pero sin segmentación. Ninguno integra ambos en IR puro para escenas interiores completas.

Aportación: Integración, implementación y evaluación experimental de un pipeline que opera exclusivamente sobre el espectro infrarrojo de un sensor accesible.

03

Metodología

Methodology

- 3.1 Arquitectura del Sistema
- 3.2 Adquisición de Datos y Preparación
- 3.3 Completado de Profundidad (Efficient-UNet)
- 3.4 Segmentación Semántica (YOLO11x-seg)
- 3.5 Reconstrucción 3D (ICP + TSDF)

Arquitectura del Sistema Propuesto

Figura 1. Pipeline del Sistema



Descripción de los Bloques

Bloque 1: Efficient-UNet recibe tensor de 5 canales (pseudo-RGB, profundidad, máscara)

Bloque 2: YOLO11x-seg + FastSAM comprenden la escena, identifican mobiliario.

Bloque 3: ICP punto-a-plano alinea fotogramas progresivamente.

Entorno: Python 3.12, PyTorch, Open3D, OpenCV, NumPy. GPU NVIDIA RTX 3080 Ti para inferencia simultánea de redes.

Adquisición de Datos y Adaptación de Dominio

Dataset SUN RGB-D

- **Total:** 10335 imágenes
- **Entrenamiento:** 70%
- **Validación:** 15%
- **Prueba:** 15%
- **Instancias:** 5,449 anotadas
- **Clases:** 17 categorías de interiores

Captura Propia (RealSense D430)

- **319 fotogramas** infrarrojos capturados
- Fine-tuning desde RGB a dominio IR
- Costo sensor: **\$200-\$300 USD**
- Alineación nativa IR+profundidad
- SDK librealsense con integración Python

Imagen **RGB**



Imagen de **profundidad incompleta**



Imagen de **profundidad "ground truth"**



Intel RealSense **D430**



Preparación y Estandarización de Datos

1 Redimensionamiento

Imágenes y mapas de profundidad a **480×640 px** (aspecto nativo 4:3 del sensor IR). Balance óptimo entre detalle y memoria GPU.

2 5 Canales de Entrada

Pseudo-RGB (3 canales duplicando IR) + canal de **profundidad** + canal de **máscara binaria** de validez.

3 Máscaras de Validez

Máscara binaria: **1=píxel válido**, 0=hueco. La Edge-Aware Loss penaliza únicamente errores en píxeles válidos.

4 Conversión Métrica

uint16 (milímetros) → **float32 (metros)**.
Estandarización uniforme para SUN RGB-D y capturas propias.

5 Clamping de Outliers

Umbral a **8.0 metros**. Purgado de "ruido de infinito" del sensor antes de alimentar la red neuronal.

6 Acceso Directo al Hardware

Script Python vía **librealsense**. Sin filtros del fabricante. Datos brutos en formato .npy preservando ruido original.



Segmentación Semántica con YOLO11x-seg

Problema: Gap de Dominio RGB→IR

YOLO11x-seg preentrenado en SUN RGB-D (color) es **incapaz de detectar objetos** en imágenes infrarrojas. Las texturas, patrón de ruido y distribución de sombras en IR son fundamentalmente distintas.

Solución: Pipeline de Transferencia


1. **FastSAM** genera pseudo-etiquetas en 319 imágenes IR (<2 min)
2. **Filtro percentil 80** descarta fondo lejano
3. **Fine-tuning** YOLO en dominio IR (60 épocas)

Configuración del Fine-Tuning en Infrarrojo


- **Learning rate:** 0.0005 (20× menor que original)
- **Optimizador:** AdamW (tasas adaptativas por parámetro)
- **Épocas:** 60
- **Principio:** Capas iniciales aprenden características generales transferibles; capas superiores se especializan en IR

Tabla 2. Ablación del Percentil de Profundidad

Percentil	Mask Ratio Mean	Min	Max
80 (seleccionado)	69.88%	0.00%	97.95%



Pipeline de Reconstrucción 3D



Detalles del Proceso Experimental

Calibración intrínseca: Los parámetros (fx, fy, cx, cy) se extrajeron de archivos CSV generados por el sensor D430 durante la captura, en lugar de usar valores genéricos de fábrica. Esto mejora la precisión de proyección de píxeles al espacio 3D.

Limpieza geométrica: El algoritmo Statistical Outlier Removal analiza la distancia promedio de cada punto hacia sus vecinos más cercanos. Puntos excesivamente alejados según umbral de desviación estándar se eliminan automáticamente.

Evaluación indirecta: Se implementó análisis de consistencia geométrica global (RANSAC sobre planos de la malla TSDF) como indicador indirecto del drift acumulado, extrayendo planos dominantes y evaluando ortogonalidad y paralelismo.

04

Resultados

Experimental Results

- 4.1 Completado de Profundidad (Efficient-UNet)
- 4.2 Segmentación Semántica (YOLO11x-seg)
- 4.3 Odometría Visual y Reconstrucción 3D

Evaluación del Completado de Profundidad

Tabla 3. Rendimiento Global (1,399 imágenes prueba)

Métrica	ResNet18 (Base)	E-UNet V1	E-UNet V2 (Prop)	Mejora V2 vs Base
$\delta < 1.25$	93.57%	98.14%	98.33%	+4.76%
MAE	0.1797 m	0.0716 m	0.0664 m	-63.1%
RMSE	0.3777 m	0.2158 m	0.2227 m	-41.0%

Tabla 4. Rendimiento en Zonas Ciegas (Huecos)

Métrica	ResNet18 (Base)	E-UNet V1	E-UNet V2 (Prop)	Mejora V2 vs Base
$\delta < 1.25$	76.91%	91.47%	92.47%	+15.56%
MAE	0.4316 m	0.2256 m	0.2179 m	-49.5%
RMSE	0.7466 m	0.4954 m	0.5080 m	-32.0%

Análisis de Resultados

- El Modelo V2 logra la mejor precisión fina (98.33%) y menor MAE (6.6 cm) a costa de ligera penalización en RMSE.
- En zonas ciegas, V2 alcanza 92.47% de precisión fina con MAE de 21.7 cm, sellando vacíos estructurales indispensables para ICP.
- El Edge-Aware Loss prioriza nitidez de bordes sobre suavizado general, generando transiciones geométricas más realistas.

Ejemplos del completado de profundidad

Completado de imagen RGB

Imagen RGB



Imagen de profundidad incompleta



Imagen de profundidad completada



Imagen de profundidad "ground truth"



Completado de imagen IR

Imagen IR



Imagen de profundidad incompleta



Imagen de profundidad completada



Resultados de Segmentación Semántica (YOLO11x-seg)

90.00%

Box mAP50
(Detección)

77.20%

Box mAP50-95
(Detección estricta)

87.82%


Mask mAP50
(Máscaras)

65.25%

Mask mAP50-95
(Máscaras estricta)

Tabla 5. Rendimiento por Categoría Semántica (Mask AP)

Categoría	AP50	AP (mAP50-95)	Observación
Suelo (floor)	94. 67%	72. 27%	Superficie continua, retorno estable
Mobiliario	89. 59%	65. 17%	Objetos volumétricos de interés
Paredes (wall)	79. 19%	58. 30%	Falta de textura en IR



Nota metodológica: El mAP de YOLO11x-seg es una métrica de consistencia interna (validación sobre pseudo-etiquetas FastSAM). No constituye una validación independiente de precisión semántica contra ground truth humano.

Métricas de Odometría Visual (ICP)

2.52 cm

ICP RMSE
Error de alineación local

95.54%

ICP Fitness
Nivel de ajuste geométrico

92.35%

Profundidad Válida

Condiciones experimentales: Secuencia de 338 fotogramas capturados → 319 integrados exitosamente tras validación por ICP. Sensor Intel RealSense D430 operando en infrarrojo puro.

Tabla 6. Métricas de Odometría Visual e Integración

Métrica de Evaluación	Resultado Promedio
Proporción de Profundidad Válida	92. 35%
ICP RMSE (Error Cuadrático Medio)	0. 0252 m (2. 52 cm)

Limitación Metodológica

El RMSE de 2.52 cm fue calculado a partir de correspondencias geométricas entre fotogramas consecutivos. **No sustituye una medición externa de trayectoria global** (requeriría ground truth con estación total o sistema de captura de movimiento).

Malla Volumétrica y Complejidad

Tabla 7. Malla TSDF Original vs. Malla Decimada Final


Métrica	Malla TSDF Original	Malla Decimada Final	Reducción
Vértices	11, 409, 829	69, 532	99. 4%
Triángulos	14, 148, 189	150, 067	98. 9%
Tamaño .ply	730. 35 MB	5. 24 MB	99. 3%

Análisis de la Malla Final

- La decimación basada en **Quadric Error Metrics** preserva detalle estructural en bordes y esquinas, colapsando triángulos redundantes en zonas planas (paredes, suelo).
- El archivo resultante de **5.24 MB** es manejable para importación directa en SketchUp, Blender y Unity.



Casa real



Reconstrucción 3D

Consistencia Geométrica Global

Tabla 8. Consistencia Geométrica Global (RANSAC)

Métrica	Valor Medido	Esperado	Desv.
Pared 0 ↔ Pared 1 (ady.)	79.98°	90.00°	-10.02°
Pared 0 ↔ Pared 3 (ady.)	83.31°	90.00°	-6.69°
Pared 1 ↔ Pared 2 (ady.)	60.59°	90.00°	-29.41°
Pared 0 ↔ Pared 2 (op.)	21.58°	0.00°	+21.58°
Pared 0 ↔ Suelo	88.17°	90.00°	-1.83°
Pared 1 ↔ Suelo	77.07°	90.00°	-12.93°

Tabla 9. vs. Medición Física

Dimensión	Real	Modelo 3D	Error
Ancho (X)	3.810 m	4.000 m	+5.0%
Largo (Y)	4.978 m	3.973 m	-20.2%
Alto (Z)	2.527 m	2.500 m	-1.1%

Análisis de Consistencia Geométrica

Ortogonalidad: Las paredes adyacentes presentan desviaciones angulares de **6.69° a 29.41°** respecto a la ortogonalidad teórica (90°). Las paredes opuestas exhiben errores de paralelismo de 18.33° y 21.58°.

Drift acumulado: Estos valores indican que el drift acumulado distorsionó la estructura arquitectónica global, consistente con la ausencia de loop closure o bundle adjustment global.

Escala métrica: El eje vertical (Z) presenta error de solo -1.1% (2.7 cm), mientras que el eje longitudinal (Y) muestra el mayor distorsión (-20.2%), consistente con la dirección dominante del movimiento de la cámara y la literatura de SLAM visual.

Conclusión: El sistema, en su configuración actual sin corrección global, presenta una limitación metodológica conocida: el drift acumulado. El RMSE de 2.52 cm a nivel local es competitivo para el hardware empleado.

Conclusiones

- 1 El pipeline integra **completado de profundidad (Efficient-UNet)**, **segmentación semántica (YOLO11x-seg)** y **odometría+TSDF** sobre espectro infrarrojo puro, demostrando viabilidad técnica.
- 2 **RMSE local 2.52 cm**, Fitness 95.54%, malla de 14M+ triángulos. Resultados positivos para sensor de -\$2,000-\$3,000 MXN sin canal RGB.
- 3 **Hipótesis parcialmente verificada:** Cualitativamente confirmada (la integración compensa deficiencias del sensor). Cuantitativamente estricta: RMSE 2.52 cm > umbral de 2 cm.
- 4 Operar en **IR puro elimina desalineación RGB-D**. La Edge-Aware Loss mejora nitidez de bordes. Las pseudo-etiquetas permiten adaptar YOLO a IR sin anotación manual.
- 5 El post-procesamiento mejora escala métrica parcialmente. El error de **-20.2% en eje longitudinal** impide validación global completa del gemelo digital.

Contribución principal: La integración de estas tres etapas en un pipeline que opera sobre el espectro infrarrojo de un sensor accesible, combinando técnicas que en la literatura se tratan por separado. La novedad reside en la combinación y adaptación conjunta al dominio infrarrojo.

Limitaciones y Trabajo Futuro

Limitaciones Identificadas

- 1. Dataset reducido:** 319 fotogramas para transferencia de dominio. Generalización no garantizada.
- 2. Sin líneas base:** No evaluado contra configuraciones alternativas (sensor sin completado, pipeline RGB-D).
- 3. Superficies problemáticas:** Vidrio, metal pulido no evaluados sistemáticamente.
- 4. GPU de gama alta:** RTX 3080 Ti requerida. Portabilidad limitada.

Trabajo Futuro

- 1. Evaluación multi-escenario:** Pruebas en múltiples entornos con condiciones adversas variadas.
- 2. Dataset ampliado:** Aumentar conjunto de transferencia de dominio para mejor generalización.
- 3. Optimización para CPU:** Reducir dependencia de GPU de gama alta.
- 4. Superficies problemáticas:** Caracterizar comportamiento en vidrio, espejos y metal pulido.

Gracias

Gracias por su atención

Presentan

René Alejandro Santos Mora

Víctor Hugo Tecpa Cisneros

Asesores: Dr. Esau Escobar Juárez, Dr. Ricardo Ramos Aguilar

UPIIT - IPN Campus Tlaxcala | TT2026-1_IA14

Agradecimiento a los asesores y al jurado evaluador

Referencias

1. *SUN RGB-D: A RGB-D Scene Understanding Benchmark Suite*. (s. f.). <https://rgbd.cs.princeton.edu/>
2. Sun, Y., Huang, Y., Schneider, L., Thies, M., Gu, M., Mei, S., Bayer, S., & Maier, A. (2024, 15 marzo). *EAGLE: An Edge-Aware Gradient Localization Enhanced Loss for CT Image Reconstruction*. arXiv.org. <https://arxiv.org/abs/2403.10695>
3. Baheti, B., Innani, S., Gajre, S., & Talbar, S. (2020). Eff-UNet: A novel architecture for semantic segmentation in unstructured environment. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*.
4. Zhao et al. (2023). *"Fast Segment Anything."* arXiv:2306.12156.
5. El Ghazouali et al. (2024). *"FusionVision: A Comprehensive Approach of 3D Object Reconstruction and Segmentation from RGB-D Cameras Using YOLO and Fast Segment Anything."* *Sensors*, 24(9), 2889.
6. Curless & Levoy (1996). *"A Volumetric Method for Building Complex Models from Range Images."* SIGGRAPH '96, pp. 303–312.
7. Iyer et al. (2018). *"Geometric Consistency for Self-Supervised End-to-End Visual Odometry."* ECCV, pp. 267–283.